

Science des données I : module 7



Test d'hypothèse du χ^2


Philippe Grosjean & Guyliann Engels

Université de Mons, Belgique
Laboratoire d'Écologie numérique



<https://wp.sciviews.org>
sdd@sciviews.org

L'inférence



Le test d'hypothèse


Le test d'hypothèse est l'outil le plus simple pour répondre à une question via l'inférence.

Il faut déterminer :

- H_0 , l'hypothèse nulle => l'affirmation à rejeter
- H_1 , l'hypothèse alternative

Distribution du χ^2

La distribution du χ^2 admet un paramètre : les degrés de liberté




Zone de rejet

Cette zone de rejet est déterminée par une probabilité nommée le seuil α fixée *avant* de réaliser le test d'hypothèse. Nous fixons ici α à 5%.

```
qchisq(0.05, 3, lower.tail = FALSE)
```

```
## [1] 7.814728
```

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.  
## Please use `linewidth` instead.  
## This warning is displayed once every 8 hours.  
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was  
## generated.
```



Situation fictive

Notre hypothèse de départ est :

H_0 : il est équiprobable d'être du groupe A, B, C ou D

Nos observation :


```
(tab <- as.table(c(A = 5, B = 10, C = 20, D = 10)))
```

```
##   A   B   C   D  
##  5  10  20  10
```

```
chisq.test(tab, p = c(A = 1/4, B = 1/4, C = 1/4, D = 1/4))
```

```
##  
## Chi-squared test for given probabilities  
##  
## data:  tab  
## X-squared = 10.556, df = 3, p-value = 0.01439
```

La **valeur p** correspond à l'aire (à droite ici) plus extrême que la valeur du χ^2_{obs}



Les conditions d'application

Assurez vous que les conditions d'application soient respectées !

- échantillonnage aléatoire et observations indépendantes,
- aucun effectif théorique (ou probabilité) sous H_0 nul,
- aucun effectif observé, si possible, inférieur à 5 (ceci n'est **pas** une condition stricte ; le test sera “approximativement” bon dans le cas contraire).