Science des données I : module 12



Critique statistique

Philippe Grosjean & Guyliann Engels

Université de Mons, Belgique Laboratoire d'Écologie numérique



https://wp.sciviews.org sdd@sciviews.org





- A quelle(s) question(s) le biologiste cherche-t-il à répondre en ayant réalisé ces mesures?
- Quelle est la variable réponse (= dépendante) et quelles sont les variable explicatives (= indépendante) dues ép indépendentes?
- Le jeu de données est-il **représentatif** de la population (échant llonnage aléatoire et observations indépendantes)?
- Quelle information ce jeu de données coutien et ? (exploration, l'atistique descriptives, représentations vraphiques)
- Comment la question biolog que se t áduit-elle en forn ulation statistique, par conséquent quelle méthodé do t être appliquée pour répondre à la question?



- A quelle(s) question(s) le biologiste cherche-t-il à répondre en ayant réalisé ces mesures ?
- Quelle est la variable réponse (= dépendante) et quelles sont les variables explicatives (= indépendantes) dans ce jeu de données ?
 - aléatoire et observations indépendant
- Quelle information ce jeu dé données coutiente.
 (exploration, statistiques descriptives, représentations yraphiques)
- Comment la question biolog que se t aduit-elle en formulation statistique, par conséquent quelle méthode doit être appliquée pour répondre à la question?



- A quelle(s) question(s) le biologiste cherche-t-il à répondre en ayant réalisé ces mesures?
- Quelle est la variable réponse (= dépendante) et quelles sont les variables explicatives (= indépendantes) dans ce jeu de données ?
- Le jeu de données est-il **représentatif** de la population (échantillonnage aléatoire et observations indépendantes) ?
- Quelle information ce jeu de données contient-t-\? (exploration, ratistique descriptives représentations praphiques)
- Comment la question biolog que se traduit-elle en formulation statistique, par conséquent quelle métrode doit être appriquée pour répondre à la question ?



- A quelle(s) question(s) le biologiste cherche-t-il à répondre en ayant réalisé ces mesures ?
- Quelle est la variable réponse (= dépendante) et quelles sont les variables explicatives (= indépendantes) dans ce jeu de données ?
- Le jeu de données est-il **représentatif** de la population (échantillonnage aléatoire et observations indépendantes) ?
- Quelle **information** ce jeu de données contient-t-il ? (exploration, statistiques descriptives, représentations graphiques)
- Comment la question biolog que se t aduit-elle en formulation statistique, par conséquent quelle méthode doit être app quée pour réponure à la question?



- A quelle(s) question(s) le biologiste cherche-t-il à répondre en ayant réalisé ces mesures ?
- Quelle est la variable réponse (= dépendante) et quelles sont les variables explicatives (= indépendantes) dans ce jeu de données ?
- Le jeu de données est-il **représentatif** de la population (échantillonnage aléatoire et observations indépendantes) ?
- Quelle information ce jeu de données contient-t-il ? (exploration, statistiques descriptives, représentations graphiques)
- Comment la question biologique se traduit-elle en formulation statistique, et par conséquent, quelle méthode doit être appliquée pour répondre à la question ?



Que faire face à une méthode statistique inconnue ?



- Rechercher un "tutorial" avec exemple réalisé dans le logiciel (aide en ligne, manuel de R. etc...).
- L'appliquer aussi à des jeux de données qu'on connaît bien, pour voir comment elle se comporte.
- Travailler avec des jeux de données artificiels que se passe t-il si...
- Rechercher dans la bibliographie des cas sim aires où la méth de a déjà été appliquée (Attention! Dans les revue) se entifiques en biologie, il y a parfois des erreurs graves... rester crivique.
- Si la nouvelle méthode s'apparente à une ou plusieurs autres connues, compare
- Si possible: décortiquer le calcul jour compre dre comment elle fonctionne



- Rechercher un "tutorial" avec exemple réalisé dans le logiciel (aide en ligne, manuel de R., etc...).
- L'appliquer aussi à des jeux de données qu'on connaît bien, pour voir comment elle se comporte.
- Travailler avec des jeux de données art ficiels que se passo (-il si...
- Rechercher dans la bibliographie des cas sim laires où la méth de a déjà été appliquée (Attention! Dans les revue) se entifiques en biologie, il y a parfois des erreurs graves... rester crivique.
- Si la nouvelle méthode s'apparente à une ou plusieurs autres connues, compare
- Si possible : décortiquer le calcul pour compre dre comment elle fonctionne



- Rechercher un "tutorial" avec exemple réalisé dans le logiciel (aide en ligne, manuel de R. etc...).
- L'appliquer aussi à des jeux de données qu'on connaît bien, pour voir comment elle se comporte.
- 3 Travailler avec des jeux de données artificiels que se passe-t-il si...?
- appliquée (Attention ! Dans les revue se entifiques en biologie, il parfois des erreurs graves... rester critiques !
- Si la nouvelle méthode s'app rente à une ou plusie es autres connues, compar
- Si possible : décortiquer le calcul pour compre dre comment elle fonccionne



- Rechercher un "tutorial" avec exemple réalisé dans le logiciel (aide en ligne, manuel de R, etc...).
- L'appliquer aussi à des jeux de données qu'on connaît bien, pour voir comment elle se comporte.
- 3 Travailler avec des jeux de données artificiels que se passe-t-il si...?
- Rechercher dans la bibliographie des cas similaires où la méthode a déjà été appliquée (Attention! Dans les revues scientifiques en biologie, il y a parfois des erreurs graves... rester critiques)!
- Si la nouvelle methode s'app rente à une ou plusie as a tres connues, compa
- Si possible: décortiquer le calcul pour compres dre comment elle fonctions



- Rechercher un "tutorial" avec exemple réalisé dans le logiciel (aide en ligne, manuel de R, etc...).
- L'appliquer aussi à des jeux de données qu'on connaît bien, pour voir comment elle se comporte.
- 3 Travailler avec des jeux de données artificiels que se passe-t-il si...?
- Rechercher dans la bibliographie des cas similaires où la méthode a déjà été appliquée (Attention! Dans les revues scientifiques en biologie, il y a parfois des erreurs graves... rester critiques)!
- 5 Si la nouvelle méthode s'apparente à une ou plusieurs autres connues, comparer.



- Rechercher un "tutorial" avec exemple réalisé dans le logiciel (aide en ligne, manuel de R., etc...).
- L'appliquer aussi à des jeux de données qu'on connaît bien, pour voir comment elle se comporte.
- 3 Travailler avec des jeux de données artificiels que se passe-t-il si...?
- Rechercher dans la bibliographie des cas similaires où la méthode a déjà été appliquée (Attention! Dans les revues scientifiques en biologie, il y a parfois des erreurs graves... rester critiques)!
- 5 Si la nouvelle méthode s'apparente à une ou plusieurs autres connues, comparer.
- 6 Si possible : décortiquer le calcul pour comprendre comment elle fonctionne.



- A quel type de **question** répond-t-elle ?
- Quel(s) type(s) de variable(s) faut-il
- Quelles sont les contraintes qu'\ faut re contrer (et donc vérifier!) pour pouvoir appliquer cette méthode (normanté, homoscédastic té, etc...)
- Existe t'il des variantes (bi- / unilatéral, pparié / non apparié)
- E Comment interpréter le résultat



- A quel type de **question** répond-t-elle?
- Quel(s) type(s) de variable(s) faut-il ?
- Quelles sont les contraintes qu'N faut rencontrer (et donc vérifier!) pour
- Existe t'il des variantes (bi- / unilatér 1, pparié / non apparié)
- 65 Comment interpréter le résultat



- 1 A quel type de **question** répond-t-elle?
- Quel(s) type(s) de variable(s) faut-il ?
- Quelles sont les **contraintes** qu'il faut rencontrer (et donc vérifier!) pour pouvoir appliquer cette méthode (**normalité**, **homoscédasticité**, **etc...**)?
- Existe t'il des variantes (bi- / unilatér d. apparié / non apparié)
- Comment interpréter le résultat



- A quel type de **question** répond-t-elle?
- Quel(s) type(s) de variable(s) faut-il ?
- Quelles sont les **contraintes** qu'il faut rencontrer (et donc vérifier!) pour pouvoir appliquer cette méthode (**normalité**, **homoscédasticité**, **etc...**)?
- Existe t'il des variantes (bi- / unilatéral, apparié / non apparié)?



- A quel type de **question** répond-t-elle ?
- Quel(s) type(s) de variable(s) faut-il?
- Quelles sont les **contraintes** qu'il faut rencontrer (et donc vérifier !) pour pouvoir appliquer cette méthode (**normalité**, **homoscédasticité**, **etc...**) ?
- Existe t'il des variantes (bi- / unilatéral, apparié / non apparié) ?
- **5** Comment **interpréter** le résultat ?



Critique statistique - mise en situation



- Bien identifier la question posée et la population étudiée
- 3 Analyser la méthode d'échantillonnage
- Rechercher des problèmes éventuels dans la definition ou la resure des
- Etre attentif aux variables confondantes q i peuvent invalider les conclusio (imaginer des scénazios alternatifs)
- 6 Comment l'étude a-t-elle été mise en place et réalis
- Vérifier que les graphiques proposé représentent les données de manière objective
- Vérifier que les conclusions finales répo dent bio la la question posée



- Bien identifier la question posée et la population étudiée
- 2 Vérifier les sources (est-il possible qu'il y ait des biais ?)
- Rechercher des problèmes éventuels dans la difinition ou la mesure des
- Etre attentif aux variables confondantes o i peuvent invalider les conclusio (imaginer des scénazios alternatifs)
- 6 Comment l'étude a-t-elle été mise en place et réalis
- Vérifier que les graphiques propose / représentent les connées de manière objective
- 💽 Vérifier que les conclusions finales répo dent bio 🗋 a question posée



- Bien identifier la question posée et la population étudiée
- **2 Vérifier les sources** (est-il possible qu'il y ait des biais ?)
- 3 Analyser la méthode d'échantillonnage utilisée
- variables (vérifier les ordres de grandeus)
- Etre attentif aux variables confondantes o i peuvent involider les conclusio (imaginer des scénarios alternatifs)
- 6 Comment l'étude a-t-elle été mise en place et réalis
- Vérifier que les graphiques proposé représentent les données de manière objective
- Vérifier que les conclusions finales répo dent bio là la question posée



- Bien identifier la question posée et la population étudiée
- **2** Vérifier les sources (est-il possible qu'il y ait des biais ?)
- 3 Analyser la méthode d'échantillonnage utilisée
- Rechercher des problèmes éventuels dans la définition ou la mesure des variables (vérifier les ordres de grandeurs)
- Etre attentif aux variables confondantes du peuvent invaluer les conclus
- 6 Comment l'étude a-t-elle été mise en place et r
- Verifier que les graphiques propose representent les connees de maniere objective
- Vérifier que les conclusions finales répodent bie à la question posée



- Bien identifier la question posée et la population étudiée
- **2** Vérifier les sources (est-il possible qu'il y ait des biais ?)
- 3 Analyser la méthode d'échantillonnage utilisée
- Rechercher des problèmes éventuels dans la définition ou la mesure des variables (vérifier les ordres de grandeurs)
- 5 Être attentif aux variables confondantes qui peuvent invalider les conclusions (imaginer des scénarios alternatifs)
- 6 Comment l'étude a-t-elle été mise en place
- Vérifier que les graphiques propose représentent les données de manière objective
- Vérifier que les conclusions finales répo dent bie) à la question posée



- Bien identifier la question posée et la population étudiée
- **Vérifier les sources** (est-il possible qu'il y ait des biais ?)
- 3 Analyser la méthode d'échantillonnage utilisée
- Rechercher des problèmes éventuels dans la définition ou la mesure des variables (vérifier les ordres de grandeurs)
- Étre attentif aux variables confondantes qui peuvent invalider les conclusions (imaginer des scénarios alternatifs)
- 6 Comment l'étude a-t-elle été mise en place et réalisée ?
- Vérifier que les graphiques proposé représentent les données de manière
- 8 Vérifier que les conclusions finales répo dent bien à la question posée



- Bien identifier la question posée et la population étudiée
- **Vérifier les sources** (est-il possible qu'il y ait des biais ?)
- 3 Analyser la méthode d'échantillonnage utilisée
- Rechercher des problèmes éventuels dans la définition ou la mesure des variables (vérifier les ordres de grandeurs)
- Étre attentif aux variables confondantes qui peuvent invalider les conclusions (imaginer des scénarios alternatifs)
- 6 Comment l'étude a-t-elle été mise en place et réalisée ?
- Vérifier que les graphiques proposés représentent les données de manière objective
- Vérifier que les conclusions finales répo dent bion à la question posée



- Bien identifier la question posée et la population étudiée
- **Vérifier les sources** (est-il possible qu'il y ait des biais ?)
- 3 Analyser la méthode d'échantillonnage utilisée
- Rechercher des problèmes éventuels dans la définition ou la mesure des variables (vérifier les ordres de grandeurs)
- Étre attentif aux variables confondantes qui peuvent invalider les conclusions (imaginer des scénarios alternatifs)
- 6 Comment l'étude a-t-elle été mise en place et réalisée ?
- Vérifier que les graphiques proposés représentent les données de manière objective
- 8 Vérifier que les conclusions finales répondent bien à la question posée



Critique statistique (1)

Un chercheur compile les statistiques de longévité de diverses professions. Pour ce faire, il encode les données des certificats de décès (nom, âge au moment du décès et profession). Il calcule ensuite l'âge moyen de décès par profession. Il constate que la valeur minimale est observée **chez les étudiants**, avec une valeur moyenne de seulement 20,7 ans (Wainer, Palmer & Bradlow, A selection of selection anomalies, *Chance*, vol. 11, n°2).

La « profession » d'étudiant est-elle réellement plus dangereuse que celle de policier, chauffeur de taxi, ou cascadeur ? Expliquez...



Critique statistique (2)

Un biologiste étudie une chauve-souris insectivore naine. Il trouve dans la littérature que la biomasse totale de cette chauve-souris varie de 0,23 à 1,95 kg/ha dans les forêts recensées. Afin de calculer l'abondance de ces populations de chauve-souris, il détermine le poids moyen d'un individu comme étant (moyenne \pm écart type) 55 ± 13 mg (n = 45). Il utilise ces données pour comparer les populations de chauve-souris aux autre animaux présents dans cette forêt. Il en conclu, enfin, que la population de chauve-souris dans ces forêts est très nettement supérieure à celle des oiseaux et équivalente à celle des insectes dans la région étudiée. Ce résultat est inattendu et permet de considérer cette chauve-souris comme espèce clé dans la chaîne trophique, alors que son effet a toujours été négligé auparavant, tant elle est discrète et passe inaperçu la plupart du temps.

Vous travaillez aussi sur les chaînes trophiques de ces mêmes forêts. Comment réagissez-vous à la lecture de ce rapport ? Que faites-vous ensuite ?



Critique statistique (3)

Le magazine "Men's Health" a publié des statistiques qui décrivent l'"homme moyen". Celui-ci a 34,4 ans, pèse 79,4kg, mesure 177,8cm, dors 6,9 heures chaque nuit, bois 3,3 tasses de café par jour et consomme 1,2 boisson alcoolique quotidiennement.

Sachant que toutes les distributions sont unimodales, donc que les valeurs moyennes correspondent toutes à des observations effectivement mesurées en grand nombres (identiques ou très proches) sur des hommes réels, ce portrait robot de l'"homme moyen" décrit-il effectivement un grand nombre d'individus réellement existants ? Justifiez. Qu'en serait-il de l'"homme médian" ?



Critique statistique (3) - Explications

Considérer un individu **moyen** est un aberration lorsque des mesures de dimensions différentes sont combinées. Pour démontrer cela simplifions à l'extrême.

- Soit une population de cubes ayant tous une masse volumique invariable et strictement égale à 1 kg/dm³.
- Prenons 3 cubes de largeurs respectives 1, 2 & 3 dm.
- largeur moyenne : (1 + 2 + 3) / 3 = 2 dm
- masse des 3 cubes : $1^3 * 1 = 1 \text{ kg}$, $2^3 * 1 = 8 \text{ kg}$, $3^3 * 1 = 27 \text{ kg}$
- masse moyenne : (1 + 8 + 27) / 3 = 12 kg
- le cube moyen a donc une largeur de 2 dm et une masse de 12 kg, soit une masse volumique de $12 / 2^3 = 12/8 = 1,5 \text{ kg/dm}^3$, ce qui ne correspond à aucun cube de la population !
- Par contre, le **cube médian** a un sens : il mesure 2 dm et sa masse est 8 kg, avec une masse volumique de 1 kg/dm³



Critique statistiques (4)

L'espérance de vie est une donnée statistique qui permet de connaître la durée de vie moyenne qu'on peut espérer atteindre à un moment donné pour une nation donnée. Cette statistique est calculée et publiée par de nombreux organismes, incluant l'OMS. Les statistiques indiquent que l'espérance de vie des hommes dans nos pays est de 75,5 ans, et des femmes de 83,5 ans.

Calculez le temps que vous pouvez espérer encore vivre en fonction de votre âge. Que pensez-vous de ce calcul ?



Critique statistique (5)

Un scientifique mesure la stabilité de la membrane lysosomale (indice de stress des cellules utilisé en écotoxicologie : on sait que les polluants étudiés tendent à déstabiliser la membrane des lysosomes) chez la moule Mytilus edulis en Mer du Nord. Deux régions sont comparées : la pleine mer (A), et l'embouchure de l'Escault dans sa partie considérée comme la plus polluée (B). Cinq moules sont prélevées aléatoirement sur les deux sites, et dix mesures sont réalisées sur chaque individu. Le scientifique conclu à une stabilité lysosomale significative plus faible au seuil alpha de 5% dans le site B (test de Student non apparié et unilatéral à gauche, t=-6,5, ddl=49, P<0.001).

Que pensez-vous de cette étude ?



Critique statistiques (6)

Trois clients dans un restaurant payent leur repas : $30 \in (10 \in \text{par personne})$. Le serveur se rend compte qu'en fait leur repas n'a coûté que $25 \in \text{en}$ tout. Comme il ne pourra diviser les $5 \in \text{à}$ rendre en trois facilement, il décide de garder $2 \in \text{dans}$ sa poche et rend $1 \in \text{à}$ chaque client. Donc, chaque client a payé $10 - 1 = 9 \in \text{,}$ soit un total de $27 \in \text{.}$ Avec les $2 \in \text{que}$ le serveur a gardé dans sa poche, cela fait $29 \in \text{.}$ Alors, où est passé l'euro manquant par rapport aux $30 \in \text{payés}$ initialement ?

Réfléchissez et dénoncer l'erreur de raisonnement dans le récit précédent.



Critique statistique (7)

Un chercheur dans une industrie chimique s'intéresse à l'effet d'un nouvel insecticide à effet progressif. Il teste son produit sur des drosophiles et observe une mortalité de 10% par jour, et ce, quel que soit le moment où il effectue les mesures après avoir mis les mouches en contact avec l'insecticide. Il en conclu qu'il faut 10 jours pour tuer toutes les mouches. Ce résultat est meilleur que le produit du concurrent, car ce dernier tue 80% des mouches sur la même durée de 10 jours.

Que pensez-vous de la façon dont cette expérience a été menée et de ses conclusion ?



Critique statistique (7) - Explications

Attention à ne pas confondre :

- Evolution linéaire (diminution de la même valeur à chaque pas de temps)
- Évolution exponentielle (diminution de la même proportion à chaque pas de temps)
- \blacksquare 10%/jour = diminution exponentielle, et ne signifie pas atteindre 0 en 10 jours
- Partons de 100 mouches
 - Jour 1: 10% mortes = 10 = reste 90
 - Jour 2: 10% mortes des 90 = 9 = reste 81
 - Jour 3: 10% mortes des 81 = environ 8 => reste 73
 - Jour 4: 10% mortes des 73 = environ 7 => reste 66
 - etc.

$$N_t = N_0 \cdot (1-a)^t$$

Ce qui donne après 10 jours pour 100 mouches au départ : $100 * (1 - 0.1)^10 = 35$. Cela signifie que l'insecticide tue 65% des mouches en 10 jour, soit **moins bien** que le produit concurrent qui en tue 80%!

Critique statistique (8)

Par le plus grand des hasards, le numéro 8 est sorti 6 fois en 7 tirages successifs du lotto. Sachant qu'une vérification de ce que ce numéro n'a pas plus de chances que les autres d'être tiré au sort, vous ne manquerez pas de constater en bon statisticien(ne) que le numéro 8 est très nettement sur-représenté dans les tirages.

La prochaine fois que vous remplirez votre grille de lotto, jouerez-vous le numéro 8 ? Pourquoi ?

Vous est-il arriver de jouer la suite 1, 2, 3, 4, 5, 6, 7, 8 au lotto (ou rempliriez-vous une grille avec ces nombres si vous deviez y jouer)? Pourquoi?

